ШАГ 1

Чтение сайта и технические проверки

GEO-аудит · Подробный алгоритм · Редакция 1.0 · 31.10.2026

Документ определяет ограниченный сбор страниц, техническую диагностику и подготовку проверяемого материала для профиля компании на шаге 2. Он учитывает исправления исходного алгоритма и использует результат шага 0. Численные пороги являются настройками первой версии, а не доказанными нормативами GEO.

1.0. Цель и границы

Собрать полезные тексты и метаданные сайта, установить наблюдаемые ограничения доступа и сохранить основания каждой проверки. На выходе должно быть понятно, какие страницы прочитаны, что помешало остальным и на каком материале можно строить профиль.

Исполнитель: Python, HTTPX, trafilatura, BeautifulSoup, protego или проверенный совместимый парсер; безопасный XML-разбор. Playwright подключается только как необязательная ограниченная диагностика. Модели и платный поиск на этом шаге не используются.

Основные исправления

Было в исходной версии	Уточнённое решение
Не менее трёх страниц по 300 символов	Ориентир покрытия; полезный одностраничник тоже допускается
Доступ 14 роботов	Документируемый реестр без искусственного фиксированного количества
Сайт одинаков для браузера и роботов	Ограниченные наблюдения по User-Agent без обещания реального доступа робота
Малый текст означает проблему JS	Сравнение исходного и rendered-текста с сохранением неопределённости
Проверка прошла / не прошла	pass, fail, warning, unknown, not_applicable с основаниями
До 30 страниц без детализации охвата	Учёт кандидатов, причин отбора, дубликатов, сбоев и остановки по лимиту

Общий порядок

Проверить вход шага 0 → получить robots → обнаружить URL → выбрать и прочитать страницы → извлечь текст → проверить директивы и транспорт → выполнить разрешённые дополнительные диагностики → оценить достаточность → сохранить результаты и передать материал шагу 2.

Выходы: crawl.json, checks.json, run.json и raw-манифест. Успех извлечения текста не означает успех всех технических проверок. Ошибка отдельной страницы не должна уничтожать данные остальных.

1. Вход, состояние запуска и подготовка

1.1. Что поступает из шага 0

Объект	Проверка перед продолжением
site.json	Известная schema_version, run_id и can_enter_step1=true
Выбранный HTML	Файл существует, хэш соответствует selected_evidence_id
effective_url и origin	Совпадают с наблюдаемым конечным ответом
allowed_hosts и path_scope	Не расширены произвольно после проверки адреса
Budget	Учтены запросы и время шага 0, общий deadline ещё не истёк
Конфигурация	Версия сохранена; есть лимиты, язык запроса и собственный User-Agent

Если вход не согласован, вернуть INPUT_ARTIFACT_INVALID. Не подставлять пустые тексты и не выдавать повреждённый результат шага 0 за успешный вход. Сохранённый входной ответ повторно не загружается только ради начала шага 1.

1.2. Инициализация

Создать очередь URL, реестр origin, хранилище ответов, карту нормализованных URL и redirect-алиасов, реестр доказательств, список проверок и счётчики. Параметры сети общие со шагом 0: фактическая проверка публичного назначения, TLS verification, ручные редиректы и ограниченные повторы.

У скрипта собственный честный User-Agent GEOAudit/0.1. Название не меняется в ответ на Disallow. Дополнительные запросы с другим User-Agent относятся только к явно включённой диагностике и не подменяют основной обход.

1.3. Разрешение чтения и сохранённая входная страница

Шаг 0 является проверкой явно введённого адреса. До автоматического чтения остальных страниц шаг 1 проверяет правила для своего обходчика. Если robots запрещает этот обход, новые страницы не запрашиваются. Уже полученный входной HTML можно сохранить и описать как ограниченное входное наблюдение; он не доказывает разрешение последующего обхода.

Поле crawl_permission имеет значения allowed, disallowed или unknown и область origin/URL. Оно отличается от can_enter_step1. Даже при disallowed/unknown сохраняются robots-наблюдения, результаты шага 0 и причина ограничения.

1.4. Условия остановки

Общий deadline, бюджет запросов, неподтверждённый внешний хост, сетевой запрет или ошибка обязательного хранения заканчивают соответствующую ветвь. Алгоритм фиксирует partial/needs_input/failed по общему правилу и сохраняет всё, что уже получено. Никакого бесконечного ожидания браузера, ответа пользователя или Retry-After.

2. Получение robots.txt

2.1. Отдельный документ для каждого origin

URL строится как origin + /robots.txt. Для http://example.com/ru/ это http://example.com/robots.txt. Разные схема, хост и порт требуют отдельных результатов. Перенос правил между HTTP и HTTPS без наблюдения недопустим. [S1, S2]

Применяется потоковый GET через общий клиент. Сохраняются исходное тело, код, заголовки, время, request_id, хэш и origin, для которого получены правила. Кэш допускается внутри запуска; между запусками нужен возраст и HTTP-валидация. Для первой реализации достаточно кэша только на время запуска.

2.2. Таблица решения для нашего обходчика

Полученный результат	Состояние и политика проекта
200, корректный текст правил	present; применить разобранные правила
200, пустой корректный файл / 204	empty; явных ограничений нет; HTTP-особенность сохранить
404/410	absent; явного robots-запрета нет
401/403	access_denied; unknown, дальнейший автоматический обход приостановить
429	Временное ограничение; учитывать Retry-After; по исчерпании бюджета unknown
5xx или сетевая ошибка	После ограниченного повтора unreachable; unknown и пауза обхода
HTML challenge вместо текста	invalid_response; не объявлять файл отсутствующим
Неполное тело, 206, превышение лимита	incomplete; не делать окончательный вывод «всё разрешено»

Консервативная остановка на 401/403 является политикой нашего продукта. Её нельзя выдавать за универсальное поведение всех поисковых систем. Техническая неизвестность также не равна директиве владельца Disallow: /. [S1, S2]

2.3. Редиректы файла

До пяти безопасных переходов robots.txt могут вести между публичными хостами. Это отдельное правило получения служебного ресурса. Проверять каждое назначение и не расширять allowed_hosts для HTML-обхода. Правила относятся к первоначальному origin, а конечный URL файла хранится отдельно. При запрещённом назначении или незавершённой цепочке результат unknown. [S1]

2.4. Размер и ошибки формата

Лимит разбора - 512 KiB. При превышении хранить доступную часть и флаг усечения; собственный обход приостановить, потому что окончательные правила неизвестны. При отдельных ошибках строк использовать корректно разобранную часть и сохранить предупреждения. HTML с несколькими случайными словами Allow нельзя автоматически считать достоверным robots.txt.

Каждое ограничение должно иметь точную причину: ROBOTS_FORBIDS, ROBOTS_UNREACHABLE, ROBOTS_ACCESS_DENIED, ROBOTS_TRUNCATED или ROBOTS_INVALID_RESPONSE. Только первое означает установленный запрет из правил.

3. Оценка правил robots по URL

3.1. Парсер и объяснимость

Использовать protego либо другой парсер с проверенной семантикой. Зафиксировать версию и набор совместимости. Регулярное выражение «есть ли Disallow» не заменяет разбор групп, путей и приоритетов. Хранить исходные строки до нормализации. [S3]

Для каждого выбранного URL оценить собственного обходчика и токены из реестра. Результат относится к точному URL и origin. Если для главной разрешено, а /services/ запрещено, отчёт должен показать оба наблюдения, а не «робот имеет доступ ко всему сайту».

3.2. Что сохранять в robots_decision

Поле	Значение
robots_evidence_id	Исходник с номерами строк
evaluated_url, origin	Адрес и область проверки
product_token	Точный токен из реестра
decision	allowed, disallowed или unknown
matched_group_lines	Группа, применённая парсером
decisive_rule_lines	Правило, определившее результат; может быть пустым
reason	Разрешение, запрет, отсутствие подходящего ограничения или невозможность оценки
parser_version	Версия и политика совместимости

При отсутствии ограничения номера решающих правил могут быть пустыми. Нельзя придумывать строку «Allow», которой нет в файле. Если парсер не выдаёт объяснение, слой сопоставления обязан подтверждать решение теми же правилами. При расхождении объяснения с парсером проверка получает unknown, а не фиктивную ссылку на строку.

3.3. Контрольные случаи

Проверить: регистр токена, специфическую группу и wildcard-группу, несколько подходящих групп, пустой Disallow, пересекающиеся Allow/Disallow, wildcard, конец шаблона, percent-encoded путь и query. Условные примеры должны проходить и прямую проверку парсера, и проверку доказательств. Особенности совместимости с конкретным провайдером отмечать отдельно. [S1, S2, S3]

3.4. Crawl-delay и частота

Если для собственного токена есть поддерживаемый Crawl-delay, использовать более строгий интервал между ним и нашим минимальным интервалом. Неподдерживаемое расширение фиксируется как raw-директива. Не приписывать всем провайдерам одинаковую поддержку нестандартных правил.

Для URL, запрещённого собственному обходчику, сохраняется запись skipped_robots и доказательство. Текст такой страницы не считается прочитанным. Наличие URL в sitemap или внутренних ссылках не отменяет Disallow.

4. Реестр роботов и смысл проверок

4.1. Структура записи реестра

robot_id, operator, product_token, purpose, robots_applicability, http_user_agent либо null, documentation_url, verified_at, registry_version и interpretation_notes. HTTP-строки брать из официальной документации с датой проверки; не составлять несуществующие агенты по названию продукта.

Начальный реестр содержит восемь токенов. Число 14 не является обязательным критерием качества. Дополнительные роботы включаются, когда документированы их роль и правила интерпретации.

Токен	Назначение / ограничение интерпретации
OAI-SearchBot	Поисковая видимость в функциях поиска ChatGPT [S4]
GPTBot	Возможное использование материалов для обучения; отдельная настройка [S4]
ChatGPT-User	Загрузки по действию пользователя; robots может не применяться [S4]
Claude-SearchBot	Поисковый обход для функций Claude [S5]
ClaudeBot	Обход, связанный с обучением моделей [S5]
Claude-User	Загрузки по пользовательскому запросу [S5]
Googlebot	Индексирование и связанные поисковые продукты [S6]
Google-Extended	Управление использованием контента; собственного HTTP UA нет [S6]

4.2. Что нельзя объединять

Запрет обучающему роботу не равен установленному запрету поискового продукта. Google-Extended не влияет на включение в Google Search и не должен использоваться как имя HTTP-запроса. У ChatGPT-User механически найденный Disallow сохраняется, но его применимость объясняется особенностями пользовательских загрузок. [S4, S6]

Для каждого токена различать robots_policy и observed_http_response. Первое вычисляется из файла, второе возможно только в отдельной диагностике. Если HTTP User-Agent отсутствует, probe получает not_applicable. Если документация устарела или неоднозначна, registry_entry_state=needs_verification, интерпретация ограничена.

4.3. Формат вывода

Корректно: «В robots.txt для OAI-SearchBot путь /services/ запрещён правилом на строке 12». Некорректно: «Вас нет в ChatGPT, потому что закрыт GPTBot». Алгоритм наблюдает техническое условие, но не устанавливает единственную причину наличия или отсутствия бренда в ответах.

Обновление реестра версионируется отдельно от алгоритма. Старый запуск сохраняет применявшийся реестр. Перед разработкой реальные UA-строки и особенности операторов проверяются по источникам, а не копируются из неофициального списка.

5. Sitemap и обнаружение URL

5.1. Источники кандидатов

Начать с входной страницы и её ссылок. Добавить Sitemap-директивы из корректно полученного robots.txt. Если их нет или они не дали результата, ограниченно проверить /sitemap.xml и /sitemap_index.xml. Не перебирать десятки предполагаемых названий.

Сохранять provenance: URL найден во входном HTML, в конкретном sitemap либо на другой прочитанной странице. При нескольких источниках сохраняется список, а не перезаписывается первое основание.

5.2. Разбор sitemap

Поддержать XML urlset и sitemapindex с namespaces, чтение loc и gzip. Внешние сущности и сетевые обращения XML-парсера запрещены. Не делать полное дерево в памяти для произвольно большого файла. lastmod, priority и changefreq сохранять как сведения издателя, без обещания их точности. [S7]

Начальные пределы: пять различных sitemap-файлов, включая индекс; до 5 MiB после распаковки на файл; до 5000 URL суммарно; глубина ссылок на sitemap до 3 в рамках пяти файлов. Повторно встретившийся sitemap не читается снова. Все попытки, в том числе стандартные пути с 404, входят в общий HTTP-бюджет.

5.3. Область

URL страниц вне разрешённых хостов/префиксов не запрашивать. Наличие ссылки в sitemap не расширяет область анализа. Sitemap на внешнем CDN по умолчанию получает skipped_external_resource; загрузка допустима только при отдельно настроенном allowed_sitemap_hosts, с общей проверкой публичного назначения. Разрешение служебного файла не разрешает HTML-обход этого CDN.

Относительные loc или другой нестандартный формат сохранить как проблему. При допустимом восстановлении адреса отметить inferred_url; не выдавать восстановленное значение за исходный корректный loc. В первой реализации безопаснее пропустить некорректную запись, сохранив причину.

5.4. Отсутствие sitemap

404, пустой, невалидный или недоступный sitemap не останавливает чтение внутренних ссылок. Проверка фиксирует ограничение обнаружения URL. Формулировка «страницы не индексируются» из отсутствия карты недопустима: карта является средством обнаружения, а не доказательством индексирования.

Если индекс больше выделенного лимита, сохранить число разобранных и пропущенных файлов, stop_reason и порядок выбора. Вывод «на сайте только столько страниц» делать нельзя. В coverage записать sitemap_truncated=true и реальное ограничение этой выборки.

6. Очередь, приоритеты и границы обхода

6.1. Детерминированный выбор

Кандидат имеет URL, источники обнаружения, предполагаемую роль, язык, приоритет и порядковый номер. Очередь сортируется по роли и устойчивому tie-breaker, чтобы одинаковый вход давал объяснимый выбор. Роль - эвристика по URL, анкору и окружению ссылки; она сохраняется с основанием.

Приоритет	Категория
0	Входная страница; главная при наличии допустимой ссылки
1	О компании, описание бизнеса
2	Основные услуги и продукты
3	Цены, тарифы и коммерческие условия
4	Контакты, география, филиалы
5	FAQ и полезные ответы
6	Остальные содержательные разделы в доступном бюджете

6.2. Лимиты очереди и дубликаты

Не более 30 выбранных HTML-кандидатов, включая входной. Неудачная загрузка расходует слот: алгоритм не заменяет каждую ошибку бесконечными новыми страницами. HTTP-повтор расходует запрос, но не создаёт новый кандидат. Наблюдаемые redirect-алиасы и точные дубликаты не считаются новыми прочитанными страницами.

Хранить максимум 5000 нормализованных кандидатов очереди. Для первой версии разрешить не более двух вариантов query на одном пути. При превышении сохранить skipped_parameter_limit. Не удалять все query: они могут задавать язык или регион. Fragment удаляется, порядок значимых параметров для сетевого запроса сохраняется.

6.3. Исключения

Не отправлять формы; не заходить в logout, корзину, личный кабинет, внутренний поиск, бесконечные календари и генераторы фильтров. Правила исключения являются конфигурацией и записываются как skip_reason. Обычный информационный адрес нельзя исключать только по случайному совпадению короткой подстроки.

Для нового origin из уже разрешённого хоста сначала получить его robots. На каждом redirect проверить область, назначение и бюджет. Неизвестный внешний хост фиксируется в pending_external_urls; его обнаружение не прерывает все остальные разрешённые ветви.

6.4. Показатели охвата

Раздельно считать discovered_urls, selected_candidates, fetch_successes, unique_html_pages, extracted_pages, useful_pages, skipped и failed. Причины пропуска не смешивать с сетевыми ошибками. По завершении хранить URL-списки или проверяемые ссылки на них. Canonical и одинаковый хэш - сигналы дублирования; при сомнении страницы сохраняются раздельно с duplicate_candidate, без необоснованного слияния.

7. HTML, основной текст и происхождение

7.1. Сохранение до преобразования

Для каждой успешной загрузки сохранить исходное тело и метаданные через общий evidence-store. Различать content-encoded body, распакованный HTML, декодированную строку и rendered DOM. Исходник не заменять «очищенной» версией. На каждом представлении фиксировать SHA-256, размер, source_evidence_id и transform_version.

В raw-манифесте хранить requested_url, effective_url, время, HTTP-статус, заголовки из разрешённого набора, charset, полноту получения и цепочку редиректов. Различные заголовки с одинаковым именем сохранять списком. Set-Cookie не включать в публичный журнал.

7.2. Извлечение

1. Применить trafilatura к декодированному HTML с сохранением значимых списков и таблиц.
2. Оценить извлечение: пусто ли оно, не состоит ли только из навигации/согласия с cookies, не потеряны ли очевидные содержательные блоки.
3. При непригодном результате выполнить fallback через BeautifulSoup: удалить script/style и явные служебные блоки, выделить main/article либо доступную содержательную область.
4. Сохранить оба кандидата, если они существенно различаются, и объяснить выбор. Не склеивать автоматически дублирующийся текст двух экстракторов.
5. Применить фиксированную нормализацию пробелов и переносов, затем вычислить длину и хэш текста. Сохранить исходное извлечение отдельно, если нормализация меняет адресацию фрагментов.

7.3. Структурированный результат страницы

Группа	Поля
Идентификация	page_id, URL, origin, fetch_id, evidence_id
Содержимое	title, h1/h2, main_text, текст таблиц/списков
Извлечение	method, extractor_version, text_chars, text_hash
Метаданные	lang, hreflang, canonical, robots directives
Качество	content_state, useful_candidate, ограничения и причины
Связи	source_evidence_id, derived_evidence_id, обнаружившие страницы

Число символов считается после заданной нормализации Unicode-пробелов; правило версии фиксируется. Текст заголовков/таблиц, уже включённый в main_text, не прибавляется повторно для оценки достаточности.

7.4. Подготовка цитат для шага 2

У будущего факта должны быть page_id, evidence_id, точный фрагмент текста и его позиция в сохранённом представлении. offsets относятся к конкретному text_hash и не обещают совпадение с байтами HTML. Тексты сайта передаются будущей модели как недоверенные данные, отделённые от инструкций; содержащиеся в них команды не становятся заданиями проекта.

8. Индексирование и ограничения фрагментов

8.1. Какие данные читать

Из HTTP-ответа - все X-Robots-Tag, включая повторяющиеся. Из HTML - meta name=robots, meta с конкретным именем робота, canonical, lang/hreflang и области data-nosnippet. Сохранять исходную запись, адресата, нормализованные токены и доказательство. rendered-директивы, если получены, хранить отдельно от исходных. [S8]

8.2. Разные вопросы - разные проверки

Проверка	Что устанавливается
robots_policy	Может ли заданный обходчик читать этот URL по файлу правил
indexing_directives	Какие явные инструкции индексирования опубликованы
snippet_directives	Какие ограничения фрагментов/использования текста обнаружены
canonical_signal	Какой канонический адрес заявлен страницей
observed_access	Как ответил сервер на конкретный запрос из нашей среды

noindex и none обрабатываются как явные директивы, с сохранением адресата. nosnippet, max-snippet и data-nosnippet не превращаются в общий «запрет ИИ»: смысл зависит от поддерживающего продукта. Применимость к Google объясняется по его документации; перенос на других операторов требует их источника. [S8]

8.3. Конфликты и неполнота

Если обнаружены несколько общих и адресованных директив, сохранить весь набор. Интерпретировать совместно только по документированной политике оператора; при неизвестном результате дать unknown с исходными значениями. Не выбирать удобную строку и не удалять конфликт.

Если страница не загружена из-за robots или доступа, её meta-правила не наблюдались. Отсутствие наблюдения нельзя превратить в «noindex не найден, проверка пройдена». Записать unknown и причину. При успешном полном чтении допустима формулировка «явный noindex в полученном HTML и заголовках не обнаружен», с указанием границ проверки.

8.4. Приоритет проблем

Директива на странице услуги и директива на служебной странице - разные по охвату наблюдения. В checks сохранять роль страницы, число затронутых прочитанных URL и доказательства. План действий на более позднем шаге сможет расставить приоритеты, не выдумывая покрытие всего сайта.

Отсутствие запретов не доказывает индексирование, цитирование или присутствие компании в нейроответах. Canonical на внешний хост фиксируется как сигнал; переход по нему не выполняется автоматически и область чтения не расширяется.

8.5. HTTPS и различия версий сайта

Повторное использование шага 0

Вначале прочитать TLS-наблюдения и redirect-цепочки шага 0. Исправный выбранный HTTPS даёт подтверждённое наблюдение для этого соединения; TLS certificate failure остаётся fail, даже если HTML удалось получить по HTTP. Не отправлять повторный запрос только ради переноса этих данных в checks.json.

Если пользователь ввёл HTTP и HTTPS ещё не проверялся, подготовить альтернативный HTTPS URL с тем же хостом, путём и query. Выполнить один ограниченный диагностический GET через общий клиент, без отключения TLS и расширения области. Допустимые временные повторы расходуют обычный бюджет. Проверка не запускает новый рекурсивный обход.

Наблюдение	Технический вывод
HTTPS соединение и сертификат проверены	https_transport=pass для наблюдаемого URL
Ошибка проверки сертификата	https_transport=fail с отдельным кодом причины
Отказ/таймаут/DNS-сбой	unknown либо warning по природе наблюдения; не «HTTPS отсутствует»
HTTPS вернул 403	TLS мог быть исправен; access и TLS оцениваются отдельно
HTTPS перенаправил на HTTP	warning: наблюдён downgrade; конечный HTML не становится HTTPS-страницей
Обе схемы дали разные страницы	Зафиксировать различие; не смешивать тексты и директивы

Выбор текста и origin

Основной входной материал остаётся связан с выбранным URL шага 0. Исправная альтернативная HTTPS-версия может стать кандидатом отдельного явно зафиксированного перехода, но не незаметной заменой уже собранного корпуса. Если пользователь предпочитает анализ HTTPS-варианта, обычный повторный запуск с этим URL даст однозначную новую выборку.

Robots для HTTP не переносится на HTTPS. Проверка доступности одной альтернативной страницы является диагностическим наблюдением; дальнейшее автоматическое чтение нового origin требует его собственных правил. Заголовки, canonical и тексты разных ответов сохраняются с разными evidence_id.

Ограничение интерпретации

Проверяется защищённость и доступность конкретного соединения из среды аудита. Этот этап не является полным аудитом TLS-конфигурации, всех сертификатных цепочек и всех узлов CDN. Если данных шага 0 достаточно, это явно отражается как reused_evidence; если бюджет закончился до проверки - unknown с причиной.

9. Диагностика JavaScript

9.1. Когда включать

Кандидаты: очень мало основного текста при наличии оболочки приложения, явный placeholder загрузки или существенное расхождение экстракторов. Само наличие script не является основанием. Выбрать максимум пять страниц с наибольшей диагностической ценностью и сохранить selection_reason.

Playwright необязателен. Если пакет, Chromium или безопасная среда недоступны, записать unknown с конкретной причиной. Отказ браузерной ветви не ломает статический обход. Если robots запрещает собственный доступ или есть подтверждённая CAPTCHA/авторизация, рендеринг не применяется для обхода.

9.2. Контролируемый запуск

Изолированный browser context без личного профиля, cookies и автоматической авторизации. Язык и базовые условия запроса согласованы со статической попыткой; различия записываются. TLS verification включена. Downloads, popups и service workers заблокированы; фоновые эффекты и методы запросов ограничены.

Для первой версии разрешены только GET/HEAD браузерных ресурсов. Если приложение требует POST, этот ресурс блокируется и ограничение сохраняется: низкий результат такого рендеринга нельзя выдавать за доказанную непригодность сайта. Общие таймауты, размеры и число подзапросов обязательны. [S9]

9.3. Условия сети

Нужен контроль фактических соединений ко всем origin, включая iframe, fetch/XHR, внешние ресурсы и попытки перехода. URL-фильтр сам по себе не защищает от DNS rebinding. При отсутствии проверенного egress-контроля браузер по умолчанию выключен и JS-проверка unknown. Публичные CDN допустимы как ограниченные ресурсы, но не становятся страницами обхода.

9.4. Сравнение результатов

Сохранить DOM, извлечь текст тем же правилом, что для статического HTML, затем сравнить объём и содержательность. Начальная эвристика: увеличение на 500+ символов и минимум вдвое при исходном тексте менее 1000 символов даёт флаг rendered_text_gain. При нулевой исходной длине использовать абсолютный порог. Эти числа настраиваются и версионируются.

Возможные результаты: observed_gain, no_material_gain, inconclusive. При превышении времени или бюджета результат inconclusive, а не «JS не работает». Даже observed_gain не доказывает, что текст недоступен всем роботам: браузер, время, cookies, регион и экстрактор также могут влиять на наблюдение.

На страницу - до 20 секунд. Ожидание завершения не зависит от бесконечного networkidle: использовать ограниченную загрузку и наблюдение стабилизации текста в пределах deadline. Всего до пяти страниц и 200 браузерных HTTP(S)-попыток на запуск.

10. User-Agent, язык и география

10.1. Сравнительные запросы

По умолчанию UA probes выключены. Основная проверка доступности токенов делается по robots. При включении выбрать до трёх страниц и до трёх документированных HTTP User-Agent. Не использовать токены без реального UA, в частности Google-Extended.

Сравнение выполняется при одинаковых Accept-Language и основных заголовках. Базовый ответ может переиспользоваться только при совпадении условий и достаточной близости времени. Новые запросы идут через общий клиент и расходуют его бюджет; запреты собственного обходчика и применимые ограничения проверяются заранее.

Сравнить код, конечный URL, тип, challenge-признаки и нормализованный основной текст. Точная разница хэшей не является достаточным основанием для блокировки: на странице могут меняться дата, баннер и персонализированный блок. Сохранить observation и ограничения.

Формулировка: «Из среды аудита с UA X получен 403, с базовым UA - HTML 200». Этот тест не доказывает поведение реального поискового робота с другим IP, TLS-профилем и инфраструктурой. При robots-запрете не выполнять пробу ради обхода; сохранить skipped_policy.

10.2. Языковые сигналы

Извлечь lang/hreflang и языковые признаки содержимого. Библиотечное определение языка допускается для достаточно длинного текста с сохранением метода; для короткой строки - unknown. Разные страницы могут быть на разных языках. Не сводить сайт к одному языку только по первой странице.

10.3. Географические сигналы

Понятие	Как хранить
Страна/адрес компании	Наблюдаемый адрес, цитата, page_id; возможны несколько
География услуг	Явные упоминания регионов и цитаты
Доменная зона	Слабый признак, отдельно от установленных адресов
Телефонный код	Признак контакта; не гарантия местонахождения
Рынок будущего измерения	Отдельная настройка пользователя, а не результат выбора TLD

В этой версии достаточно структурированных сигналов; извлекать окончательную бизнес-географию будет профиль на следующем шаге. Противоречия сохраняются. Если данных нет, values=[] и state=unknown. Не подставлять страну выполнения скрипта как страну компании.

Смешанный сайт с московским и казахстанским адресами не обязан давать единственную страну. Будущему шагу передаются обе цитаты и происхождение; пользователь сможет определить нужный рынок без потери исходных наблюдений.

11. Бюджеты, повторы и частичная остановка

11.1. Начальные пределы всего прохода 0-1

Ресурс	Лимит
Общее время	300 секунд, включая шаг 0 и браузер
HTTP-попытки без браузера	150, включая шаг 0, redirects, retries, robots, sitemap, probes
Выбранные HTML-кандидаты	30, включая входной
Конкурентность / интервал на хост	До 2 активных; начало не чаще раза в секунду
Повторы временной ошибки	До 2 дополнительно; не сверх общего бюджета
Redirect hops	До 5 на цепочку
HTML / robots	5 MiB / 512 KiB после распаковки
Sitemap	5 файлов × 5 MiB; до 5000 URL; глубина 3
Очередь URL	До 5000; до 2 query-вариантов на путь
Browser	До 5 страниц × 20 секунд; до 200 запросов суммарно
UA probes	До 3 страниц × 3 агента; выключены по умолчанию

11.2. Общий планировщик

Лимит проверяется перед каждой попыткой, а счётчик резервируется атомарно до отправки. Один HTTP redirect с последующим GET расходует две попытки. Повтор тоже расходует попытку. Решение из кэша увеличивает cache_hit, но не requests_sent. Браузерные попытки считаются отдельно; общая длительность едина.

Между хостами допускается ограниченная параллельность, но глобальный предел и приоритет очереди сохраняются. Не запускать все 30 страниц одновременно. Ошибки одной задачи собираются в результат; остальные ограниченные ветви могут завершиться.

11.3. Повторы и ожидание

Политика временных ошибок общая со шагом 0. Retry-After не игнорируется ради попадания в пяти минутный предел: если ждать дольше остатка, записать RETRY_DEFERRED и закончить ветвь. Ошибки сертификата, постоянные 4xx, robots-запрет и подтверждённый challenge не повторяются автоматически с другой личностью.

11.4. Завершение

При дедлайне отменить незавершённые операции, закрыть потоки/браузер и атомарно сохранить уже готовые результаты. Отмена не должна удалять raw завершённых запросов. В run.json записать stop_reason, незавершённые URL и spent/remaining counters. Если дедлайн исчерпан до всех дополнительных проверок, они получают unknown с BUDGET_EXHAUSTED.

Пользовательский partial-результат должен объяснять охват: «Прочитано 18 страниц; лимит времени остановил остальные проверки». Формулировка «весь сайт проверен» недопустима. Для повторного запуска создаётся новая версия наблюдений; silent append без согласования run_id запрещён, чтобы не удвоить счётчики.

12. Достаточность материала и переход

12.1. Что считается полезной страницей

Успешно полученный содержательный HTML, из которого извлечено не менее 300 нормализованных символов основного текста, без подтверждённого challenge, входа, soft-404 или преобладающего служебного содержимого. Релевантность бизнесу является отдельным признаком; юридический текст из 5000 символов не гарантирует материал для профиля.

Порог 300 - начальная эвристика. Не обрезать полезную короткую контактную страницу: она сохраняется как supporting_page, хотя не повышает useful_pages. Объём текста разных представлений одного URL не суммируется.

Наблюдение	material_state	Переход
3+ полезные страницы с бизнес-материалом	usable	Шаг 2 возможен; охват всё равно ограничен
1-2 полезные страницы	limited	Шаг 2 возможен с отметкой ограниченного покрытия
Текст есть, но нет подтверждённого описания бизнеса	insufficient	Попросить описание, сохранить тексты
Нет полезного материала	needs_description	Шаг 2 не запускать автоматически
Пользователь добавил пригодное описание	user_supported	Шаг 2 возможен с явным происхождением

Число страниц не является доказательством полноты профиля. Итоговое can_start_step2 выводится из доступного материала и известных ограничений, а не из одного количества страниц.

12.2. Пользовательское описание

Принимать через аргумент/файл или будущий интерфейс, без input() внутри библиотеки. Сохранить author_type=user, время, текст и source_type=user_provided. Не придумывать page_id или цитату с сайта для такого факта. Короткое пустое/бессодержательное описание вернуть на уточнение с причиной, а не выдавать за достаточный профиль.

Описание не исправляет robots, TLS, sitemap или индексирование. Например, material_state=user_supported допускает профиль, а crawl_permission=unknown и проверка HTTPS=fail остаются в технических результатах.

12.3. Общий статус шага

ok - основной ограниченный проход завершён и материал пригоден; это не означает отсутствие найденных проблем. partial - полезная часть получена, но есть сбои, лимиты или непроведённые включённые проверки. needs_input - нужен адрес/хост/описание. failed - нет достоверного результата или нарушено обязательное хранение.

Опциональная выключенная проверка имеет not_applicable с CONFIG_DISABLED и сама по себе не делает весь запуск partial. Если она включена, но технически не выполнена, это unknown и ограничение запуска. Отдельно сохранить status каждой проверки: обнаруженный noindex может дать fail проверке, но не технический failed всему выполнению.

13. Контракты crawl.json и checks.json

13.1. Общие поля

Все артефакты содержат schema_version, algorithm_version, run_id, config_hash, registry_version, started_at/finished_at и ссылки на доказательства. Время хранится в UTC, зона отображения отдельно. Файлы записываются атомарно после сохранения необходимых исходников.

13.2. Минимальный page-объект

```
{
  "page_id": "page-003",
  "url": "https://example.com/services/",
  "fetch_state": "success",
  "evidence_id": "ev-html-003",
  "text_evidence_id": "ev-text-003",
  "title": "Услуги",
  "extraction_method": "trafilatura",
  "text_chars": 1450,
  "useful_candidate": true,
  "business_relevance": "observed",
  "discovered_from": ["page-001"],
  "selection_reason": "services_priority"
}
```

В crawl.json также находятся main_text или ссылка на его текстовый артефакт, заголовки, ссылки, исходные директивы, роли, сведения о sitemap, языковые/географические сигналы, coverage и material_state. Режим встраивания текста должен быть одинаково определён схемой, а не меняться от страницы к странице произвольно.

13.3. Минимальный check-объект

```
{
  "check_id": "robots-policy-003",
  "kind": "robots_policy",
  "url": "https://example.com/services/",
  "robot_id": "oai-searchbot",
  "status": "fail",
  "observation": "disallowed",
  "evidence_ids": ["ev-robots-001"],
  "decisive_rule_lines": [12],
  "reason_code": "ROBOTS_FORBIDS",
  "limitation": "Не измеряет факт показа бренда в ответах"
}
```

Примеры учебные. Полная проверка содержит observed_at, версию правила и её область. Слово fail означает обнаруженное проверяемое препятствие в этой области. unknown означает невозможность установить результат; warning - наблюдаемое ограничение или подозрение, не равное доказанному запрету.

При валидации проверить уникальность page_id/check_id, существование каждого evidence_id и отсутствие ссылок на страницу другого запуска. Хэш текста связан с версией нормализации. Числа coverage пересчитываются из page-состояний, а не вводятся вручную.

14. Оркестрация, хранение и передача

14.1. Последовательность функций

1. load_step0_result() - проверить вход и сохранить контекст исходной проверки.
2. fetch_and_evaluate_robots() - определить собственную политику для origin и подготовить диагностику токенов.
3. discover_urls() - ссылки и разрешённые sitemap в заданных лимитах.
4. select_and_fetch_pages() - очередь, robots для каждого URL, общий бюджет и запись результатов.
5. extract_page_material() - текст, структура, происхождение и качество.
6. evaluate_directives_and_https() - технические проверки с переиспользованием шага 0; недостающая HTTPS-проверка для явного HTTP отдельно.
7. run_optional_diagnostics() - включённые UA probes и безопасный browser в остатке бюджета.
8. summarize_material_and_coverage() - пригодность, охват и условия следующего этапа.
9. validate_and_persist() - raw-манифест, crawl/checks/run, самопроверка и понятное завершение.

14.2. Псевдокод

```
site, evidence, budget = verify_step0_input()
robots = load_robots(site.origin, budget)
record_robot_checks(robots, site.effective_url)
queue = discover_from_saved_entry(site, evidence)
if own_crawl_allowed(robots):
    queue += discover_from_sitemaps(robots, budget)
    for candidate in bounded_priority_queue(queue):
        page = fetch_or_skip(candidate, robots, budget)
        preserve_and_extract(page)
        add_internal_links_with_limits(page, queue)
evaluate_static_checks()
run_enabled_diagnostics_with_remaining_budget()
material = assess_material(pages, user_description)
persist_partial_or_complete_result(material)
```

14.3. Доказательства и воспроизводимость

Структура каталога: site.json, crawl.json, checks.json, run.json, raw/manifest.json и исходники. Имена исходных файлов строятся из внутренних ID, а не внешнего пути URL. Производный DOM и извлечённый текст имеют свои типы и source_evidence_id. Манифест записывается до артефактов, которые на него ссылаются.

Если верификация обязательных доказательств не проходит, соответствующие проверки не выдаются как достоверные. Ошибка диска сообщается явно. Исходный пользовательский PDF и данные другого запуска не перезаписываются.

14.4. Контракт для шага 2

Передать полезные и поддерживающие тексты, page/evidence ID, ограничения охвата, пользовательские материалы с происхождением, список вариантов языков/географии и technical checks. Шаг 2 обязан цитировать наблюдённый материал и не превращать неопределённую географию в установленный факт. Технические ограничения не исчезают после построения профиля.

15. Приёмка будущей реализации

15.1. Обязательные сценарии

Сценарий	Проверяемый результат
Полезный одностраничник	limited; шаг 2 допустим; нет искусственного барьера 3 страниц
Три длинные служебные страницы	Недостаточность бизнеса не скрыта большим числом символов
robots разрешает главную, запрещает услуги	Решения различаются по URL; запрещённый GET не выполнен
robots 404 и robots 503	Разные состояния; 503 не становится «всё открыто»
Внешний robots-редирект	Файл применён к первому origin; HTML scope не расширен
Несколько групп и пересекающиеся правила	Парсер и объяснение согласованы; номера строк верны
Sitemap отсутствует / повреждён / зациклен	Ссылки читаются; лимиты не превышены
Параметрическая ловушка	Очередь и число кандидатов ограничены
Повторяющиеся X-Robots-Tag	Все значения и адресаты сохранены
noindex на услуге, нет данных по другой странице	Первая проверка fail, вторая unknown
Google-Extended	Есть политика; нет выдуманного HTTP probe
JS добавляет основной текст	Сохранены оба представления и наблюдение роста
Браузер отсутствует / нет egress-контроля	Статический проход работает; JS unknown
UA получил 403, базовый запрос 200	Описано конкретное наблюдение без обещания о реальном роботе
Пользовательское описание	Происхождение user_provided; технические fail не исправлены
Deadline / Retry-After за его пределом	Частичные результаты сохранены; задержка не игнорируется

15.2. Проверка целостности

Сравнить HTTP-счётчики с журналом тестового транспорта. Проверить, что сумма состояний выбранных кандидатов объясняет coverage; повторные HTTP-попытки не добавляют страницы. Все evidence_id разрешаются в артефакты и хэши. Неизвестные и выключенные проверки имеют разные причины.

Тесты основного конвейера выполняются офлайн на фикстурах. Для браузера нужен контролируемый пример изменения DOM и отдельная проверка сетевого ограничения. Если browser integration не была реально запущена, это должно быть указано в отчёте разработки, даже если unit-тесты прошли.

15.3. Критерий завершения

Реализация готова к использованию в проекте, когда выдаёт согласованные JSON, соблюдает пределы, сохраняет доказательства и позволяет однозначно объяснить каждую пропущенную страницу и каждую проверку. Полный обход интернета и гарантированное установление причин GEO-видимости в этот критерий не входят.

16. Источники и версия методики

16.1. Основа

Пользовательский «Алгоритм GEO-аудита сайта», 9 страниц, 31.10.2026; неизменённая копия находится в docs/source/. Эта редакция развивает шаг 1 вместе с отдельным документом шага 0. Подробности HTTP fallback и первичной проверки адреса определены там.

16.2. Официальная документация

S1. RFC 9309 - протокол robots, получение файла, ошибки и редиректы.

S2. Google: интерпретация robots.txt - область правил и особенности поискового робота.

S3. Protego: документация проекта - поддерживаемый парсер и его интерфейс.

S4. OpenAI: crawlers - назначение токенов и пользовательские загрузки.

S5. Anthropic: crawlers - ClaudeBot, Claude-SearchBot и Claude-User.

S6. Google: common crawlers - Googlebot и Google-Extended.

S7. Sitemaps protocol - XML urlset и sitemapindex.

S8. Google: robots meta и X-Robots-Tag - адресованные директивы и ограничения фрагментов.

S9. Playwright Python: network - управление сетевыми запросами браузера.

S10. HTTPX: transports - инъекция транспорта и воспроизводимые тесты.

S11. HTTPX: SSL - проверка TLS и сертификата для отдельного HTTPS-наблюдения.

Документация проверена в ходе подготовки проекта 31.10.2026. Реестр, библиотеки и особенности операторов должны иметь собственную дату проверки в работающем скрипте. Источники описывают поведение протоколов и продуктов; бюджеты и правила достаточности материала установлены этой методикой.

16.3. Что дополнительно уточнено в редакции 1.0

По сравнению с общим черновиком формализованы: crawl_permission и can_start_step2; conservative policy для неоднозначного robots; лимит очереди и query-вариантов; глубина sitemap; выключенный и технически неисполненный browser; эвристика rendered_text_gain; отделение исполнительного статуса от обнаруженной технической проблемы. Эти детали относятся к данной версии и не должны незаметно менять старые измерения.

Исходные данные не перезаписываются. При изменении нормализации, выбора страниц, порога достаточности, интерпретации директив или browser-режима фиксируются algorithm_version и config_hash. В документе нет результатов реального аудита и нет утверждения, что скрипт уже реализован.